# 十分钟入门pandas

本节代码来自: 黄海广-机器学习 https://github.com/fengdu78/WZU-machine-learning-course 推荐自学

Pandas是基于Numpy构建的,让Numpy为中心的应用变得更加简单。

这个一篇针对pandas新手的简短入门,想要了解更多复杂的内容,参阅Cookbook

通常,我们首先要导入以下几个库:

```
In [2]: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

# 创建对象

通过传递一个list来创建Series, pandas会默认创建整型索引:

```
In [3]: s = pd.Series([1,3,5,np.nan,6,8])
s
Out[3]: 0    1.0
    1    3.0
    2    5.0
    3    NaN
    4    6.0
    5    8.0
    dtype: float64
```

通过传递一个numpy array, 日期索引以及列标签来创建一个DataFrame:

```
In [4]: dates = pd.date range('20230101', periods=6)
        dates
Out[4]: DatetimeIndex(['2023-01-01', '2023-01-02', '2023-01-03', '2023-01-04',
                       '2023-01-05', '2023-01-06'],
                      dtype='datetime64[ns]', freq='D')
In [5]: df = pd.DataFrame(np.random.randn(6,4), index=dates, columns=list('ABCD'))
Out[5]:
                         Α
                                           C
                                                    D
        2023-01-01 -0.474649 -1.033131 -0.221292 1.123945
        2023-01-02 -1.862598 -0.608146 -0.382219 2.711038
        2023-01-03 0.430390 0.001635 -0.626828
                                              0.647631
        2023-01-04 2.206153 -0.095317 0.193339 -1.389618
        2023-01-05 -0.661550 0.019897
                                     1.039454 0.139001
        2023-01-06 -1.651088 0.304878 0.532442 0.649129
        通过传递一个能够被转换为类似series的dict对象来创建一个DataFrame:
In [6]: df2 = pd.DataFrame({ 'A' : 1.,
                             'B' : pd.Timestamp('20230102'),
                             'C' : pd.Series(1,index=list(range(4)),dtype='float32'),
                             'D' : np.array([3]*4,dtype='int32'),
                             'E' : pd.Categorical(["test","train","test","train"]),
                             'F' : 'foo' })
        df2
Out[6]:
                      B C D
                                   E F
        0 1.0 2023-01-02 1.0 3 test foo
        1 1.0 2023-01-02 1.0 3 train foo
        2 1.0 2023-01-02 1.0 3 test foo
        3 1.0 2023-01-02 1.0 3 train foo
```

#### 可以看到各列的数据类型为:

```
In [7]: df2.dtypes

Out[7]: A     float64
B     datetime64[ns]
C     float32
D     int32
E     category
F     object
dtype: object
```

# 查看数据

查看frame中头部和尾部的几行:

```
In [8]: df.head()
Out[8]:
                                              C
                                                       D
         2023-01-01 -0.474649 -1.033131 -0.221292 1.123945
         2023-01-02 -1.862598 -0.608146 -0.382219
                                                  2.711038
         2023-01-03 0.430390 0.001635 -0.626828
                                                  0.647631
         2023-01-04 2.206153 -0.095317 0.193339 -1.389618
         2023-01-05 -0.661550 0.019897 1.039454
                                                  0.139001
In [9]: df.tail(3)
Out[9]:
                                             C
                           Α
                                     В
                                                       D
         2023-01-04 2.206153 -0.095317 0.193339 -1.389618
         2023-01-05 -0.661550 0.019897 1.039454 0.139001
         2023-01-06 -1.651088 0.304878 0.532442 0.649129
```

显示索引、列名以及底层的numpy数据

```
In [10]: df.index
Out[10]: DatetimeIndex(['2023-01-01', '2023-01-02', '2023-01-03', '2023-01-04',
                       '2023-01-05', '2023-01-06'],
                      dtype='datetime64[ns]', freq='D')
In [11]: df.columns
Out[11]: Index(['A', 'B', 'C', 'D'], dtype='object')
 In [ ]: df.values
         describe()能对数据做一个快速统计汇总
 In [ ]:
        df.describe()
         对数据做转置:
 In [ ]: df.T
         按轴进行排序:
 In [ ]: df.sort_index(axis=1, ascending=False)
         按值进行排序:
 In [ ]: df.sort_values(by='B')
```

## 数据选择

标准的Python/Numpy的表达式能完成选择与赋值等功能,

不推荐使用优化过的pandas数据访问方法: .at, .iat, .loc, .iloc和.i

尽管有性能上的优化, 但是对初学者不友好.

### 选取

选择某一列数据,它会返回一个Series,等同于df.A:

```
In [17]: df['A']
Out[17]: 2023-01-01 -0.474649
         2023-01-02
                    -1.862598
         2023-01-03 0.430390
         2023-01-04 2.206153
         2023-01-05 -0.661550
         2023-01-06 -1.651088
         Freq: D, Name: A, dtype: float64
         通过使用[]进行切片选取:
In [18]: df[0:3]
                                            C
                                                    D
Out[18]:
         2023-01-01 -0.474649 -1.033131 -0.221292 1.123945
         2023-01-02 -1.862598 -0.608146 -0.382219 2.711038
         2023-01-03 0.430390 0.001635 -0.626828 0.647631
In [19]: df['20230102':'20230104']
Out[19]:
                                            C
                                                     D
         2023-01-02 -1.862598 -0.608146 -0.382219 2.711038
         2023-01-03 0.430390 0.001635 -0.626828 0.647631
         2023-01-04 2.206153 -0.095317 0.193339 -1.389618
```

#### 布尔索引

用某列的值来选取数据

```
In [20]: df[df.A > 0]
Out[20]:
                        Α
                                                  D
         2023-01-03 0.430390 0.001635 -0.626828 0.647631
         2023-01-04 2.206153 -0.095317 0.193339 -1.389618
         用where操作来选取数据
 In [ ]: df[df > 0]
         用isin()方法来过滤数据
In [22]: df2 = df.copy()
 In [ ]: df2['E'] = ['one', 'one', 'two', 'three', 'four', 'three']
In [24]: df2[df2['E'].isin(['two', 'four'])]
Out[24]:
                                                   Е
         2023-01-03 0.43039 0.001635 -0.626828 0.647631 two
         2023-01-05 -0.66155 0.019897 1.039454 0.139001 four
         赋值
         赋值一个新的列,通过索引来自动对齐数据
In [25]: s1 = pd.Series([1,2,3,4,5,6], index=pd.date_range('20230102',periods=6))
         s1
```

```
Out[25]: 2023-01-02
                     1
        2023-01-03
        2023-01-04
        2023-01-05
        2023-01-06
        2023-01-07
        Freq: D, dtype: int64
 In [ ]: df['F'] = s1
        通过标签赋值
 In [ ]: df['A'] = 0
        df
        通过位置赋值
 In []: df["B"][0] = 0
        df
        通过传递numpy array赋值
 In [ ]: df['D'] = np.array([5] * len(df))
        df
        通过where操作来赋值
 In [ ]: df2 = df.copy()
        df2[df2 > 0] = -df2
        df2
```

# 缺失值处理

在pandas中,用np.nan来代表缺失值,这些值默认不会参与运算。

reindex()允许你修改、增加、删除指定轴上的索引,并返回一个数据副本。

## 运算

## 统计

运算过程中,通常不包含缺失值。

进行描述性统计

```
In [35]: df.mean()

Out[35]: A     0.0000000
     B     -0.062842
     C     0.089149
     D     5.000000
     F     3.000000
     dtype: float64
```

对其他轴进行同样的运算

```
In [ ]: df.mean(1)

对于拥有不同维度的对象进行运算时需要对齐。除此之外,pandas会自动沿着指定维度计算。

In [ ]: s = pd.Series([1,3,5,np.nan,6,8], index=dates).shift(2) s,df

In [ ]: df.sub(s, axis='index')
```

## Apply 函数作用

通过apply()对函数作用

### 字符串方法

对于Series对象,在其str属性中有着一系列的字符串处理方法。就如同下段代码一样,能很方便的对array中各个元素进行运算。值得注

In [ ]: s.value\_counts()

意的是,在str属性中的模式匹配默认使用正则表达式。

```
In [43]: s = pd.Series(['A', 'B', 'C', 'Aaba', 'Baca', np.nan, 'CABA', 'dog', 'cat'])
         s.str.lower()
Out[43]: 0
                 а
         1
                 b
         2
                 С
         3
              aaba
         4
              baca
               NaN
              caba
               dog
               cat
         dtype: object
```

# 合并

## Concat 连接

pandas中提供了大量的方法能够轻松对Series,DataFrame和Panel对象进行不同满足逻辑关系的合并操作

通过concat()来连接pandas对象

```
In []: df = pd.DataFrame(np.random.randn(10,4))
df

In []: #break it into pieces
    pieces = [df[:3], df[3:7], df[7:]]
    pieces

In []: pd.concat(pieces)
```

### Join 合并

类似于SQL中的合并(merge)

## Append 添加

将若干行添加到dataFrame后面

```
In [ ]: df = pd.DataFrame(np.random.randn(8, 4), columns=['A', 'B', 'C', 'D'])
In [51]: s = df[2:3]
Out[51]: A B C D
2 -0.136514 1.104717 0.290601 0.429694
In [ ]: df.append(s, ignore_index=True)
```

## 数据透视表

我们可以轻松地从这个数据得到透视表

```
In [ ]: pd.pivot_table(df, values='D', index=['A', 'B'], columns=['C'])
```

## 时间序列

pandas在对频率转换进行重新采样时拥有着简单,强大而且高效的功能(例如把按秒采样的数据转换为按5分钟采样的数据)。这在金融领域很常见,但又不限于此。

```
In [ ]: rng = pd.date range('1/1/2023', periods=10, freq='S')
         rng
 In [ ]: ts = pd.Series(np.random.randint(0,100,len(rng)), index=rng)
         ts
In [57]: rng = pd.date range('1/1/2023', periods=5, freq='D')
         rng
Out[57]: DatetimeIndex(['2023-01-01', '2023-01-02', '2023-01-03', '2023-01-04',
                        '2023-01-05'],
                       dtype='datetime64[ns]', freq='D')
In [58]: ts = pd.Series(np.random.randn(len(rng)), index=rng)
         ts
Out[58]: 2023-01-01 -1.839138
         2023-01-02 -0.173644
                    0.629050
         2023-01-03
         2023-01-04
                     0.008660
         2023-01-05
                    -0.270236
         Freq: D, dtype: float64
```


#### 时间跨度转换

```
In [59]: rng = pd.date_range('1/1/2023', periods=5, freq='M')
         rng
Out[59]: DatetimeIndex(['2023-01-31', '2023-02-28', '2023-03-31', '2023-04-30',
                        '2023-05-31'],
                       dtype='datetime64[ns]', freq='M')
In [60]: ts = pd.Series(np.random.randn(len(rng)), index=rng)
         ts
Out[60]: 2023-01-31
                     -0.000015
         2023-02-28
                     -0.433859
         2023-03-31
                     1.607081
         2023-04-30
                     0.007694
         2023-05-31
                       0.101212
         Freq: M, dtype: float64
```

## 绘图

```
In [61]: ts = pd.Series(np.random.randn(1000), index=pd.date_range('1/1/2000', periods=1000))
    ts = ts.cumsum()
    ts.plot()
```


Out[61]: <AxesSubplot:>



#### 对于DataFrame类型, plot()能很方便地画出所有列及其标签

```
In [62]: df = pd.DataFrame(np.random.randn(1000, 4), index=ts.index, columns=['A', 'B', 'C', 'D'])
    df = df.cumsum()
    plt.figure(); df.plot(); plt.legend(loc='best')
```

Out[62]: <matplotlib.legend.Legend at 0x15aff8de850> <Figure size 432x288 with 0 Axes>



# 获取数据的I/O

#### **CSV**

写入一个csv文件

```
In [64]: df.to_csv('data/foo.csv')

从一个csv文件读入

In []: pd.read_csv('data/foo.csv')
```

#### **Excel**

MS Excel的读写

写入一个Excel文件

```
In [66]: df.to_excel('./foo.xlsx', sheet_name='Sheet1')
从一个excel文件读入
In []: pd.read_excel('./foo.xlsx', 'Sheet1', index_col=None, na_values=['NA'])
```